



CS 412 Intro. to Data Mining

Chapter 3. Data Preprocessing

Jiawei Han, Computer Science, Univ. Illinois at Urbana-Champaign, 2017





Chapter 3: Data Preprocessing

- Data Preprocessing: An Overview 
now process
- Data Cleaning
- Data Integration → รวมข้อมูล หลายๆ Data base (จำนวน x, y)
- Data Reduction and Transformation
ลดขนาดของ Data *เปลี่ยนค่า*
- Dimensionality Reduction → *ถ้า Dimension เยอะไป ไม่สามารถอธิบายได้ทั้งหมด
,, หักออกไม่ได้ D_i ที่สำคัญ*
- Summary

What is Data Preprocessing? — Major Tasks

☐ Data cleaning

- ☐ Handle missing data, smooth noisy data, identify or remove outliers, and resolve inconsistencies

☐ Data integration

- ☐ Integration of multiple databases, data cubes, or files

☐ Data reduction

- ☐ Dimensionality reduction
- ☐ Numerosity reduction
- ☐ Data compression

☐ Data transformation and data discretization

- ☐ Normalization
- ☐ Concept hierarchy generation

เตรียมใจ ขาดไป 100%

Why Preprocess the Data? — Data Quality Issues

- ❑ Measures for data quality: A multidimensional view
 - ❑ Accuracy: ^{Data ผิด → แก้ไขข้อมูล} correct or wrong, accurate or not
 - ❑ Completeness: not recorded, unavailable, ...
 - ❑ Consistency: some modified but some not, dangling, 
 - ❑ Timeliness: timely update?
จู่ๆ เบลอ 1-4 อักเอน A - F
 - ❑ Believability: how trustable the data are correct?
↳ ก.101 Data อาจจะไม่ตรงกับ
ตัวแปลที่จริง
 - ❑ Interpretability: how easily the data can be understood?

Chapter 3: Data Preprocessing

- ❑ Data Preprocessing: An Overview
- ❑ Data Cleaning or Data Cleansing 
- ❑ Data Integration
- ❑ Data Reduction and Transformation
- ❑ Dimensionality Reduction
- ❑ Summary

Data Cleaning

ตัวอักษร เพราะ บางที Data อาจจะมีตัวอักษร
ที่ผิดพลาดได้หลายอย่างใน ค. เก็บข้อมูล
จึงต้องทำความสะอาด Data ก่อน

- ❑ Data in the Real World Is Dirty: Lots of potentially incorrect data, e.g., instrument faulty, human or computer error, and transmission error
- ❑ Incomplete: lacking attribute values, lacking certain attributes of interest, or containing only aggregate data
 - ❑ e.g., *Occupation* = " " (missing data) Ex. ไฟดับ ไม่ป้อนข้อมูล แล้วไปใช้ข้อมูลหลัง ค่อย
- ❑ Noisy: containing noise, errors, or outliers
 - ❑ e.g., *Salary* = "-10" (an error)
- ❑ Inconsistent: containing discrepancies in codes or names, e.g.,
 - ❑ *Age* = "42", *Birthday* = "03/07/2010" กรอกอายุ , แล้ววันเกิด แต่พอคำนวณว. แล้วมันไม่ตรงกัน
 - ❑ Was rating "1, 2, 3", now rating "A, B, C"
 - ❑ discrepancy between duplicate records → อันไหนควรเก็บ อันไหนควรลบออก
- ❑ Intentional (e.g., *disguised missing data*) ข้อมูลที่ถูกใส่ไว้เพื่อไม่ให้คนอื่นรู้ Data ใจ
 - ❑ Jan. 1 as everyone's birthday?

เหตุผล อาจไม่กรอกวันเกิด แล้วใส่ Default เป็นวันที่ 1 มกราคม (คนอื่นกรอกก็จะได้วันที่ 1 มกราคมด้วย)

Incomplete (Missing) Data

- ❑ Data is not always available
 - ❑ E.g., many tuples have no recorded value for several attributes, such as customer income in sales data
- ❑ Missing data may be due to *missing data ภาวะที่ขาด*
 - ❑ Equipment malfunction *เครื่องจักรพัง*
 - ❑ Inconsistent with other recorded data and thus deleted *ข้อมูลไม่เข้าพวก เลยถูกลบทิ้งไป*
 - ❑ Data were not entered due to misunderstanding
 - ❑ Certain data may not be considered important at the time of entry
 - ❑ Did not register history or changes of the data *ข้อมูลเก่าๆ ไม่ค่อยสนใจ หรือถ้ามีก็ไม่ได้บันทึก*
- ❑ Missing data may need to be inferred

How to Handle Missing Data?

- ❑ Ignore the tuple: usually done when class label is missing (when doing classification)—not effective when the % of missing values per attribute varies considerably → Drop missing (ลบแถว)
- ❑ Fill in the missing value manually: tedious + infeasible? → งค. รู้เกี่ยวกับ Data แล้ว ดูข้อมูล missing แล้วใส่ตัวเลข (เช่น ถ้าว่าง 1000 แทน ก็ใส่ 1000)
- ❑ Fill in it automatically with
 - ❑ a global constant : e.g., “unknown”, a new class?! dummy
 - ❑ the attribute mean → เติมค่ากลาง
 - ❑ the attribute mean for all samples belonging to the same class: smarter → เติมด้วย ค่าเฉลี่ยของข้อมูลที่อยู่ใน class เดียวกัน → ฉลาดกว่าแบบเฉลี่ยรวม ex mean age, sex หรือ mean อาชีพ
 - ❑ the most probable value: inference-based such as Bayesian formula or decision tree →
 - the most probable value
 - เติมด้วย ค่าที่น่าจะเป็นมากที่สุด
 - ใช้วิธีคำนวณจากโมเดล เช่น Bayesian formula หรือ Decision tree

แก้ missing โดยใช้ model งบค. ทำด้วย

Noisy Data

- ❑ **Noise:** random error or variance in a measured variable

- ❑ **Incorrect attribute values** may be due to

- ❑ Faulty data collection instruments
- ❑ Data entry problems
- ❑ Data transmission problems
- ❑ Technology limitation
- ❑ Inconsistency in naming convention

- ❑ **Other data problems**

- ❑ Duplicate records
- ❑ Incomplete data
- ❑ Inconsistent data



How to Handle Noisy Data?


- Binning (ทัว) ง่าย ๆ
 - First sort data and partition into (equal-frequency) bins
 - Then one can **smooth by bin means**, **smooth by bin median**, **smooth by bin boundaries**, etc.
- Regression
 - Smooth by fitting the data into regression functions
- Clustering
 - Detect and remove outliers
- Semi-supervised: Combined computer and human inspection
 - Detect suspicious values and check by human (e.g., deal with possible outliers)

วิธีแก้ Noisy ↓

สัญญาณไม่ดี
ที่รบกวน → ค่า Data ที่ผิดปกติ = Noisy


Binning (กำหนด ขน. ถัง) -> แบ่ง Data ออกเป็น ค่าต่าง ๆ
หลาย ๆ ตัว

ค่าจริงที่เก็บได้
↑





Mean Median
แทนด้วยค่ากลางของ Bin
boundaries
(ค่าบน, ค่าล่าง)


↓
สรุปเป็นข้อมูลจริง ด้วยค่ากลางของ Bin เป็นชุด



Regression



Sin (cos tan)



Data Cleaning as a Process

❑ Data discrepancy detection

- ❑ Use metadata (e.g., domain, range, dependency, distribution)
- ❑ Check field overloading
- ❑ Check uniqueness rule, consecutive rule and null rule
- ❑ Use commercial tools
 - ❑ Data scrubbing: use simple domain knowledge (e.g., postal code, spell-check) to detect errors and make corrections
 - ❑ Data auditing: by analyzing data to discover rules and relationship to detect violators (e.g., correlation and clustering to find outliers)

❑ Data migration and integration

- ❑ Data migration tools: allow transformations to be specified
 - ❑ ETL (Extraction/Transformation/Loading) tools: allow users to specify transformations through a graphical user interface
- ## ❑ Integration of the two processes
- ❑ Iterative and interactive (e.g., Potter's Wheels)

Chapter 3: Data Preprocessing

- ❑ Data Preprocessing: An Overview
- ❑ Data Cleaning
- ❑ Data Integration 
- ❑ Data Reduction and Transformation
- ❑ Dimensionality Reduction
- ❑ Summary

Data Integration

□ Data integration

Data Integration X ภาระงาน → ถ้ามันไม่ได้บรรทัดเท่ากัน หรือ ..

□ Combining data from multiple sources into a coherent store

ส่วนข้อมูลกันไม่ได้

□ Schema integration: e.g., A.cust-id $\equiv$ B.cust-#

→ ต้องใช้ชื่อของ primary key

□ Integrate metadata from different sources

2 ตาราง ซ้าย-ขวา แทน X

ตารางแนวนอน → แล้วตารางสอง ถ้ามีบรรทัดที่ผิดด้วย
แล้วมันกับ มันจะไม่รู้จริงหรือไม่

□ Entity identification:

□ Identify real world entities from multiple data sources, e.g., Bill Clinton = William Clinton

→ Error

□ Detecting and resolving data value conflicts

ข้อมูลบาง 2 ข้อมูล (อาจจะมีคนละปี) แทน y

→ รูปแบบการเก็บ และปีอาจต่างกัน Ex. 1) A, B, C, D 2) 1, 2, 3, 4

□ For the same real world entity, attribute values from different sources are different

□ Possible reasons: different representations, different scales, e.g., metric vs. British units

Handling Redundancy in Data Integration

- ❑ Redundant data occur often when integration of multiple databases
 - ❑ *Object identification*: The same attribute or object may have different names in different databases
 - ❑ *Derivable data*: One attribute may be a “derived” attribute in another table, e.g., annual revenue
- ❑ **Redundant attributes may be able to be detected by *correlation analysis* and *covariance analysis***
- ❑ Careful integration of the data from multiple sources may help reduce/avoid redundancies and inconsistencies and improve mining speed and quality

เลือก Data $\rightarrow$ ตัดทอนสร้าง Model ตามเวลา / ไม่เป็นอิสระ $\rightarrow$ ต้องใส่ข้อมูลตามเวลา / ไม่เป็นอิสระเข้าๆ กัน เพื่อให้ Model สามารถเรียนรู้ได้

(sampling) แทน y แสดงแถว แสดงจุดต่าง ^{ตาม} 100 คน ฝน, 100 คน ไม่ฝน

(dimension) แทน x แสดงมิติ เช่น ไม่รู้ว่าจะอยู่กับตัวอะไรต่ออะไร เช่น Model หารถติด ต้องบอกเวลารถ ก็ไม่ได้อะไรเลย

Dimensionality Reduction

❑ Curse of dimensionality

- ❑ When dimensionality increases, data becomes increasingly sparse *ข้อมูลกระจายตัวมากขึ้น (sparse มากขึ้น)*
- ❑ Density and distance between points, which is critical to clustering, outlier analysis, becomes less meaningful *จุดใกล้-จุดห่างกันมากขึ้น และ ทั้งจุดใกล้กับ จุดไกล จะอยู่ใกล้กัน ยิ่งมิติเยอะ ยิ่งปัญหามาก*
- ❑ The possible combinations of subspaces will grow exponentially

❑ Dimensionality reduction

- ❑ Reducing the number of random variables under consideration, via obtaining a set of principal variables

❑ Advantages of dimensionality reduction *ลด dimension*

- ❑ Avoid the curse of dimensionality
- ❑ Help eliminate irrelevant features and reduce noise
- ❑ Reduce time and space required in data mining *ช่วยเพิ่มความเร็ว model ได้บ้าง*
- ❑ Allow easier visualization

Dimensionality Reduction Techniques

- Dimensionality reduction methodologies
 - **Feature selection:** Find a subset of the original variables (or features, attributes)
 - Ex. PCA
 - **Feature extraction:** Transform the data in the high-dimensional space to a space of fewer dimensions
- Some typical dimensionality methods
 - Principal Component Analysis
 - Supervised and nonlinear techniques
 - Feature subset selection
 - Feature creation

คือ ตัวที่มีด.รู้ เรื่อง Data หนึ่งตัว

เลือกเฉพาะบางคุณสมบัติที่เกี่ยวข้อง


ทำด.ในมิติที่ด.สมด.ส.ไว้ทำ ให้ด.ง่ายขึ้น เพื่อลดมิติข้อมูล

ข้อมูลคล้ายกัน รวมข้อมูลเป็นด.ลักษณะ

PCA พัดตัดจุด ดูแกนที่ข้อมูลกระจาย ย้ายข้อมูลไปแกนที่
สามารถใช้ข้อมูลได้ดีกว่า


Principal Component Analysis (PCA)

- ❑ PCA: A statistical procedure that uses an orthogonal transformation to convert a set of observations of possibly correlated variables into a set of values of linearly uncorrelated variables called *principal components*
- ❑ The original data are projected onto a much smaller space, resulting in dimensionality reduction
- ❑ Method: Find the eigenvectors of the covariance matrix, and these eigenvectors define the new space



Ball travels in a straight line. Data from three cameras contain much redundancy

PCA (Principle Component Analysis)



- 1. Standardizing the Data (ปรับ mean และ std ให้ มี mean=0 std=1)
- 2. Calculating the Covariance matrix (หา covariance matrix ของข้อมูลของเรา)
- 3. Computing the Eigenvectors and Eigenvalues (คำนวณ eigen values-vectors)
- 4. Picking Principal Components Using the Explained Variance (เลือกมาเฉพาะ eigens ที่จำเป็น)
- 5. Project Data Onto Lower-Dimensional Linear Subspace (map data ไปบนแกนใหม่)

<https://wendynavarrete.com/principal-component-analysis-with-numpy/>

ขั้นตอนคณิตศาสตร์ที่สำคัญที่สุด

- Eigenvector = ทิศทางใหม่ของแกน (ทิศที่มีข้อมูลกระจายมากที่สุด)
- Eigenvalue = บอกว่าแกนนั้นสำคัญมากแค่ไหน (อธิบายข้อมูลได้มากแค่ไหน)

ง่าย ๆ:

- eigenvector = "ทิศ" นอกโลก
- eigenvalue = "ความสำคัญของทิศนั้น" ฝึก.กระจายรอบแกนนั้นแต่ไม่ใช่

PCA step by step

ปรับทุก dimension

1. ดู Memory ของมัน (เอา Memory ไม่ลบออกจากตัวบวกรวมๆ)
Data ถูกเปลี่ยนมาทั้งหมด

[]

```
1 import pandas as pd
```

load data

- กราฟมันจะถูกบีบอัด

ถ้า Z score

2. covariance matrix

eigen V นอร์ดอง sum ของ eigen V

4 Picking Principal Components Using the Explained Variance (เลือกเฉพาะ eigens ที่จำเป็น)

PCA เลือกเฉพาะ eigens ที่จำเป็น

คำนวณว่า แต่ละ eigen vector อธิบายข้อมูลทั้งหมด ได้ดีแค่ไหน

```
1 sum(eigen_values)
4.026845637583896
```

```
1 variance_explained = []
2 for i in eigen_values:
3     variance_explained.append((1/sum(eigen_values))*100)
4
5 print(variance_explained)
```

เลือก 2 เวกเตอร์ = PCA1 + PCA2 = 95% อธิบายข้อมูลได้ 95%

การเลือกเฉพาะ eigens ที่จำเป็น

```
[72.77045209380132, 23.03052326768066, 3.6838319576273824, 0.5151926888906327]
```

เลือกเฉพาะ eigens ที่จำเป็น

```
1 cumulative_variance_explained = np.cumsum(variance_explained)
2 print(cumulative_variance_explained)
```

```
... [ 72.77045209  95.80097536  99.48480732 100.]
```


```
1 selected_eigen_vectors = eigen_vectors[:, :2]
2 selected_eigen_vectors
```

```
array([[ 0.52237162, -0.37231836],
       [-0.26335492, -0.92555649],
       [ 0.58125401, -0.02109478],
       [ 0.56561105, -0.06541577]])
```

5 Project Data Onto Lower-Dimensional Linear Subspace (map data ไปบนแกนใหม่)

Principal Component Analysis (Method)


- Given N data vectors from n -dimensions, find $k \leq n$ orthogonal vectors (*principal components*) best used to represent data
 - Normalize input data: Each attribute falls within the same range
 - Compute k orthonormal (unit) vectors, i.e., *principal components*
 - Each input data (vector) is a linear combination of the k principal component vectors
 - The principal components are sorted in order of decreasing “significance” or strength
 - Since the components are sorted, the size of the data can be reduced by eliminating the *weak components*, i.e., those with low variance (i.e., using the strongest principal components, to reconstruct a good approximation of the original data)
- Works for numeric data only



Ack. Wikipedia: Principal Component Analysis

Attribute Subset Selection

- Another way to reduce dimensionality of data
- Redundant attributes
 - Duplicate much or all of the information contained in one or more other attributes
 - E.g., purchase price of a product and the amount of sales tax paid
- Irrelevant attributes
 - Contain no information that is useful for the data mining task at hand
 - Ex. A student's ID is often irrelevant to the task of predicting his/her GPA



- Data ที่สัมพันธ์กันมาก จนในที่สุดข้อมูลซ้ำกัน → เลือกใช้หนึ่งเดียว

- ลบ Data ออกทิ้งที่เป็นข้อมูลที่ไม่เกี่ยวข้อง
Ex. model ทำนายโรค แต่ใส่ข้อมูลเกรง

ก. เลือกทิ้งแล้วเลือกอันใหม่

- ไล่ดู. รู้เลยว่าเรา

- เลือกจากกฎเกณฑ์ที่เราจัดไว้

Heuristic Search in Attribute Selection

- ❑ There are 2^d possible attribute combinations of d attributes
- ❑ Typical heuristic attribute selection methods:
 - ❑ Best single attribute under the attribute independence assumption: choose by significance tests
 - ❑ Best step-wise feature selection:
 - ❑ The best single-attribute is picked first
 - ❑ Then next best attribute condition to the first, ...
 - ❑ Step-wise attribute elimination:
 - ❑ Repeatedly eliminate the worst attribute
 - ❑ Best combined attribute selection and elimination
 - ❑ Optimal branch and bound:
 - ❑ Use attribute elimination and backtracking

Attribute Creation (Feature Generation)

- ❑ Create new attributes (features) that can capture the important information in a data set more effectively than the original ones
- ❑ Three general methodologies
 - ❑ Attribute extraction
 - ❑ Domain-specific
 - ❑ Mapping data to new space (see: data reduction)
 - ❑ E.g., Fourier transformation, wavelet transformation, manifold approaches (not covered)
 - ❑ Attribute construction
 - ❑ Combining features (see: discriminative frequent patterns in Chapter on “Advanced Classification”)
 - ❑ Data discretization

Summary

- ❑ **Data quality:** accuracy, completeness, consistency, timeliness, believability, interpretability
- ❑ **Data cleaning:** e.g. missing/noisy values, outliers
- ❑ **Data integration** from multiple sources:
 - ❑ Entity identification problem; Remove redundancies; Detect inconsistencies
- ❑ **Data reduction, data transformation and data discretization**
 - ❑ Numerosity reduction; Data compression
 - ❑ Normalization; Concept hierarchy generation
- ❑ **Dimensionality reduction**

References

- ❑ D. P. Ballou and G. K. Tayi. Enhancing data quality in data warehouse environments. *Comm. of ACM*, 42:73-78, 1999
- ❑ T. Dasu and T. Johnson. *Exploratory Data Mining and Data Cleaning*. John Wiley, 2003
- ❑ T. Dasu, T. Johnson, S. Muthukrishnan, V. Shkapenyuk. [Mining Database Structure; Or, How to Build a Data Quality Browser](#). SIGMOD'02
- ❑ H. V. Jagadish et al., Special Issue on Data Reduction Techniques. *Bulletin of the Technical Committee on Data Engineering*, 20(4), Dec. 1997
- ❑ D. Pyle. *Data Preparation for Data Mining*. Morgan Kaufmann, 1999
- ❑ E. Rahm and H. H. Do. Data Cleaning: Problems and Current Approaches. *IEEE Bulletin of the Technical Committee on Data Engineering*. Vol.23, No.4
- ❑ V. Raman and J. Hellerstein. *Potters Wheel: An Interactive Framework for Data Cleaning and Transformation*, VLDB'2001
- ❑ T. Redman. *Data Quality: Management and Technology*. Bantam Books, 1992
- ❑ R. Wang, V. Storey, and C. Firth. A framework for analysis of data quality research. *IEEE Trans. Knowledge and Data Engineering*, 7:623-640, 1995

